

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления» Кафедра ИУ5 «Системы обработки информации и управления»

Отчет

по дисциплине «Технология Машинного обучения»

Выполнил: студент группы ИУ5-62 Миронов Святослав подпись, дата

Задание:

• Выбрать набор данных (датасет). Вы можете найти список свободно распространяемых датасетов здесь.

Для лабораторных работ не рекомендуется выбирать датасеты большого размера.

- Создать ноутбук, который содержит следующие разделы:
- 1. Текстовое описание выбранного Вами набора данных.
- 2. Основные характеристики датасета.
- 3. Визуальное исследование датасета.
- 4. Информация о корреляции признаков.
- Сформировать отчет и разместить его в своем репозитории на github.

Lab1_end

June 3, 2019

```
In [1]: !pip install seaborn

DEPRECATION: Python 2.7 will reach the end of its life on January 1st, 2020. Please upgrade your Requirement already satisfied: seaborn in /usr/local/lib/python2.7/dist-packages (0.9.0)
Requirement already satisfied: matplotlib>=1.4.3 in /usr/lib/python2.7/dist-packages (from sea Requirement already satisfied: numpy>=1.9.3 in /usr/local/lib/python2.7/dist-packages (from sea Requirement already satisfied: pandas>=0.15.2 in /usr/local/lib/python2.7/dist-packages (from sea Requirement already satisfied: scipy>=0.14.0 in /usr/local/lib/python2.7/dist-packages (from sea Requirement already satisfied: pytz>=2011k in /usr/lib/python2.7/dist-packages (from pandas>=0 Requirement already satisfied: python-dateutil>=2.5.0 in /usr/lib/python2.7/dist-packages (from pandas>=0 from sklearn import datasets import matplotlib.pyplot as plt import seaborn as sns

%matplotlib inline
```

1 Data Set Information:

This database contains 76 attributes, but all published experiments refer to using a subset of 14 of them. In particular, the Cleveland database is the only one that has been used by ML researchers to this date. The "goal" field refers to the presence of heart disease in the patient. It is integer valued from 0 (no presence) to 4.

1.1 Attribute Information:

- 1. age
- 2. sex
- 3. chest pain type (4 values)
- 4. resting blood pressure
- 5. serum cholestoral in mg/dl
- 6. fasting blood sugar > 120 mg/dl

In [3]: df = pd.read_csv('heart.csv', sep=",")

7. resting electrocardiographic results (values 0,1,2)

- 8. maximum heart rate achieved
- 9. exercise induced angina
- 10. oldpeak = ST depression induced by exercise relative to rest
- 11. the slope of the peak exercise ST segment
- 12. number of major vessels (0-3) colored by flourosopy
- 13. thal: 3 = normal; 6 = fixed defect; 7 = reversable defect

120

```
In [4]: df.shape
Out[4]: (303, 14)
In [5]: df.head()
Out [5]:
                            trestbps
                                       chol
                                                              thalach
                                                                                 oldpeak
            age
                                              fbs
                                                    restecg
                                                                        exang
                  sex
                        ср
         0
             63
                    1
                         3
                                  145
                                         233
                                                 1
                                                           0
                                                                   150
                                                                             0
                                                                                     2.3
         1
                         2
                                                           1
                                                                   187
                                                                             0
                                                                                     3.5
             37
                    1
                                  130
                                         250
                                                 0
         2
                                                           0
                                                                   172
                                                                             0
                                                                                     1.4
             41
                    0
                         1
                                  130
                                         204
                                                 0
         3
             56
                    1
                         1
                                  120
                                         236
                                                 0
                                                           1
                                                                   178
                                                                             0
                                                                                     0.8
```

354

1

163

1

0.6

slope

0

0

2

2

2

```
thal
                target
   ca
0
     0
             1
                       1
            2
1
     0
                       1
2
     0
            2
                       1
3
             2
     0
                       1
4
     0
```

0

In [6]: df.dtypes

4

57

```
Out[6]: age
                        int64
                        int64
         sex
                        int64
         ср
                        int64
        trestbps
         chol
                        int64
                        int64
        fbs
        restecg
                        int64
        thalach
                        int64
                        int64
         exang
         oldpeak
                      float64
         slope
                        int64
                        int64
         ca
        thal
                        int64
        target
                        int64
        dtype: object
```

_

In [7]: df.isnull().sum()

```
Out[7]: age
                     0
                     0
        sex
                     0
        ср
        trestbps
                     0
        chol
                     0
                     0
        fbs
        restecg
                     0
        thalach
                     0
                     0
        exang
        oldpeak
                     0
        slope
                     0
                     0
        ca
                     0
        thal
                     0
        target
        dtype: int64
In [8]: df['target'].unique()
Out[8]: array([1, 0])
In [9]: df.describe()
Out [9]:
                        age
                                     sex
                                                   ср
                                                         trestbps
                                                                           chol
                                                                                         fbs
        count
                303.000000
                             303.000000
                                          303.000000
                                                       303.000000
                                                                    303.000000
                                                                                 303.000000
                 54.366337
                               0.683168
                                            0.966997
                                                       131.623762
                                                                    246.264026
                                                                                   0.148515
        mean
        std
                  9.082101
                               0.466011
                                            1.032052
                                                        17.538143
                                                                     51.830751
                                                                                   0.356198
        min
                 29.000000
                               0.00000
                                            0.000000
                                                        94.000000
                                                                    126.000000
                                                                                   0.00000
        25%
                                                       120.000000
                                                                    211.000000
                 47.500000
                               0.00000
                                            0.000000
                                                                                   0.00000
        50%
                 55.000000
                               1.000000
                                            1.000000
                                                       130.000000
                                                                    240.000000
                                                                                   0.000000
        75%
                 61.000000
                                                       140.000000
                               1.000000
                                            2.000000
                                                                    274.500000
                                                                                   0.00000
                 77.000000
                               1.000000
                                            3.000000
                                                       200.000000
                                                                    564.000000
                                                                                   1.000000
        max
                                thalach
                                                          oldpeak
                   restecg
                                                exang
                                                                          slope
                                                                                          ca
                                                       303.000000
                                                                    303.000000
        count
                303.000000
                             303.000000
                                          303.000000
                                                                                 303.000000
                  0.528053
                             149.646865
                                            0.326733
                                                         1.039604
                                                                      1.399340
                                                                                   0.729373
        mean
        std
                  0.525860
                              22.905161
                                            0.469794
                                                         1.161075
                                                                      0.616226
                                                                                   1.022606
                  0.000000
                              71.000000
                                            0.000000
                                                         0.000000
                                                                      0.000000
                                                                                   0.000000
        min
        25%
                  0.000000
                             133.500000
                                            0.000000
                                                         0.000000
                                                                      1.000000
                                                                                   0.000000
        50%
                  1.000000
                             153.000000
                                            0.000000
                                                         0.800000
                                                                      1.000000
                                                                                   0.000000
        75%
                  1.000000
                             166.000000
                                            1.000000
                                                         1.600000
                                                                      2.000000
                                                                                   1.000000
                  2.000000
                             202.000000
                                            1.000000
                                                         6.200000
                                                                      2.000000
        max
                                                                                   4.000000
                                 target
                      thal
                303.000000
                             303.000000
        count
```

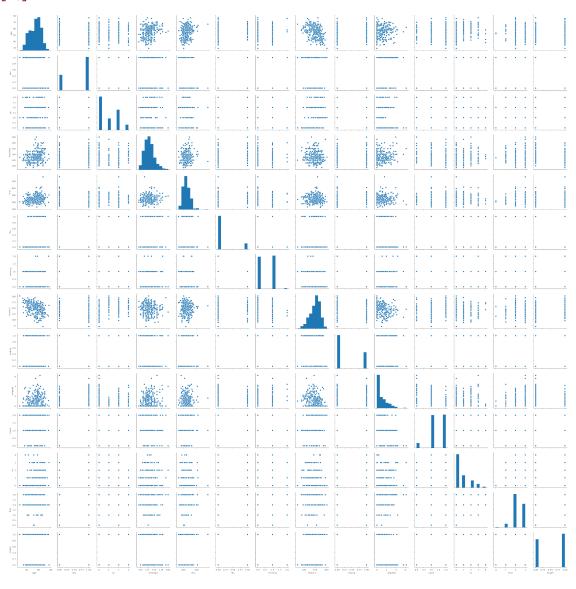
mean	2.313531	0.544554
std	0.612277	0.498835
min	0.000000	0.000000
25%	2.000000	0.000000
50%	2.000000	1.000000
75%	3.000000	1.000000
max	3.000000	1.000000

-,

In [10]: sns.pairplot(data= df)

Out[10]: <seaborn.axisgrid.PairGrid at 0x7f2287a89940>

Out[10]:







- 0.9

0.6

0.3

0.0

- -0.3